INFORME TÉCNICO

Clasificación de Imágenes Mediante Fine-Tuning de MobileViT

Evaluación Comparativa de Variantes de Arquitectura y Estrategias de Preprocesamiento

Maestría en Inteligencia Artificial – FIUBA

Materia: Visión por Computadora III

Alumnos: Lucas Didoné, Carlos Villalobos y Emmanuel Cardozo

Versión 2.0 | Abril 2025

Dataset: tf_flowers (TensorFlow/Hugging Face) | Modelos: MobileViT XXS, XS

Referencia base: apple/mobilevit-small (Hugging Face)

1. Resumen Ejecutivo

Este informe documenta el diseño, implementación y evaluación de tres modelos de visión por computadora basados en la arquitectura **MobileViT** para la tarea de clasificación multiclase de imágenes. Los tres modelos fueron desarrollados a partir del checkpoint preentrenado **apple/mobilevit-small** disponible en Hugging Face, y entrenados sobre el dataset público **tf_flowers**, que comprende 3,670 imágenes distribuidas en cinco categorías botánicas.

El estudio evalúa el impacto progresivo de tres estrategias: (i) entrenamiento desde cero sobre la variante más compacta (XXS), (ii) fine-tuning supervisado sobre la variante XS con preprocesamiento estándar, y (iii) fine-tuning sobre XS con una pipeline de preprocesamiento optimizada. Los resultados demuestran mejoras sostenidas en la exactitud de validación, alcanzando un máximo del **96%** en el tercer escenario, lo que posiciona a MobileViT como una solución competitiva para despliegues en dispositivos con recursos computacionales limitados.

2. Objetivo del Proyecto

El objetivo principal de este proyecto es implementar y evaluar la eficacia de la arquitectura **MobileViT** —un Transformer de visión ligero diseñado para dispositivos móviles— en la tarea de clasificación de imágenes, utilizando el dataset **tf_flowers**. En concreto, se persiguen los siguientes objetivos específicos:

- Analizar el comportamiento del modelo MobileViT XXS entrenado desde cero, sin transferencia de conocimiento.
- Cuantificar la ganancia de rendimiento obtenida mediante fine-tuning con pesos preentrenados en ImageNet-1k.
- Evaluar el impacto de estrategias avanzadas de preprocesamiento y aumento de datos sobre la exactitud de validación.
- Comparar la viabilidad de cada configuración para su despliegue en entornos con restricciones de cómputo y memoria.

3. Arquitectura del Modelo

3.1 Descripción General

MobileViT es una arquitectura híbrida que combina las ventajas de las Redes Neuronales Convolucionales (CNN) —eficientes en la captura de características espaciales locales— con la capacidad de los Transformers para modelar dependencias globales de largo alcance, manteniendo al mismo tiempo una baja latencia de inferencia.

La arquitectura procesa imágenes de entrada de 256×256 píxeles a través de una secuencia de **bloques convolucionales** estándar, seguidos de **bloques MobileViT** que constituyen el núcleo diferenciador del modelo.

3.2 Componentes Clave

Bloques de Convolución Local

Procesan la imagen en las etapas iniciales para reducir progresivamente la resolución espacial y extraer características locales de bajo nivel (bordes, texturas). Operan de forma eficiente mediante convoluciones separables en profundidad (depthwise separable convolutions).

Bloques MobileViT

Constituyen el núcleo de la arquitectura. Su operativa comprende cuatro sub-etapas:

- Convolución local para captura de contexto inmediato.
- "Desenrollado" (unfold) de la imagen en parches no solapados de tamaño definido.
- Aplicación de un Transformer sobre los parches para modelar relaciones globales entre regiones distantes.
- "Reenrollado" (fold) de los parches transformados en el mapa de características original.

Separable Self-Attention (MobileViT v2)

Reduce la complejidad computacional de la atención de $O(k^2)$ a $O(k)$, donde k es el número de parches, permitiendo una inferencia significativamente más rápida y adecuada para dispositivos móviles.

3.3 Variantes Evaluadas

Variante	Parámetros aprox.	Estrategia	Val Accuracy
MobileViT XXS	~1 M	Entrenamiento desde cero	**79%**
MobileViT XS	~2.3 M	Fine-tuning (dataset estándar)	**85%**
MobileViT XS	~2.3 M	Fine-tuning + preprocesamiento avanzado	**96%**

4. Implementación Técnica

4.1 Stack Tecnológico

- TensorFlow 2.13 / Keras — framework principal de entrenamiento e inferencia.
- Hugging Face Transformers — carga de modelos preentrenados, procesadores de imagen y finetuning de los modelos utilizados.
- Dataset tf_flowers — benchmark estándar de clasificación botánica.
- TFLite — formato objetivo para despliegue en dispositivos móviles.

4.2 Dataset: tf_flowers

El dataset **tf_flowers** contiene **3,670 imágenes** distribuidas en cinco clases de flores: diente de león (dandelion), margarita (daisy), tulipán (tulips), girasol (sunflowers) y rosa (roses). La configuración del modelo refleja este esquema de clasificación, con índices de clase del 0 al 4 según el mapeo definido en el archivo **config.json**.

4.3 Pipeline de Preprocesamiento

El procesador de imágenes (MobileViTImageProcessor) aplica las siguientes transformaciones sobre cada muestra:

- Redimensionamiento al borde más corto: 288 px (interpolación bicúbica, resample=2).
- Recorte central (center crop) a resolución 256×256 px.
- Inversión del orden de canales (BGR → RGB) mediante do_flip_channel_order.
- Reescalado de valores de píxel al rango [0, 1] con factor 1/255 (≈ 0.00392).

El modelo con menor rendimiento, entrenado desde cero y sin transferencia de conocimiento, incorporó adicionalmente técnicas de data augmentation: volteo horizontal aleatorio, ajuste de brillo y contraste, y rotaciones menores, lo que reduce el sobreajuste y mejora la generalización.

4.4 Configuración del Modelo

Los parámetros de arquitectura relevantes extraídos del archivo config.json son:

- Tamaño de imagen de entrada: 256×256 px, 3 canales (RGB).
- Tamaños ocultos (hidden_sizes): [144, 192, 240].
- Función de activación: SiLU (Swish).
- Número de cabezas de atención (multi-head): 4.
- Dropout en clasificador: 10%; dropout en atención: 0%.
- Tipo de problema: clasificación de una sola etiqueta (single_label_classification).

5. Evaluación y Métricas de Desempeño

5.1 Métrica Principal

La métrica principal utilizada para la evaluación es la **exactitud de validación (Validation Accuracy)**, definida como la proporción de imágenes correctamente clasificadas sobre el total del conjunto de validación. Dado que el dataset tf_flowers presenta una distribución de clases aproximadamente balanceada, esta métrica resulta representativa del desempeño global del modelo.

5.2 Resultados Comparativos

Modelo	Configuración	Descripción	Val Accuracy
MobileViT XXS	~1 M params	Entrenamiento desde cero, sin transferencia de conocimiento, con técnicas de Data Augmentation. Demuestra la capacidad base de la arquitectura ligera.	**79%**
MobileViT XS	~2.3 M params	Fine-tuning con pesos preentrenados en ImageNet-1k y pipeline de preprocesamiento estándar.	**85%**
MobileViT XS	~2.3 M params	Fine-tuning con pesos preentrenados en ImageNet-1k y pipeline de preprocesamiento optimizada.	**96%**

6. Análisis de Resultados

6.1 Modelo 1: MobileViT XXS — Entrenamiento desde Cero (79%)

Alcanzar un 79% de exactitud de validación con el modelo XXS entrenado desde cero es un resultado **notable considerando que el modelo cuenta únicamente con aproximadamente 1 millón de parámetros**. Este resultado evidencia que la arquitectura MobileViT es intrínsecamente capaz de aprender representaciones visuales discriminativas incluso sin transferencia de conocimiento previa, lo cual resulta relevante en escenarios donde no se dispone de modelos base compatibles o donde la privacidad de los datos impide el uso de preentrenamiento externo.

6.2 Modelo 2: MobileViT XS — Fine-Tuning Estándar (85%)

La incorporación de pesos preentrenados en ImageNet-1k mediante fine-tuning eleva la exactitud de validación en **6 puntos porcentuales** respecto al entrenamiento desde cero. Este resultado confirma la hipótesis clásica de la transferencia de aprendizaje: las representaciones de bajo y medio nivel aprendidas sobre millones de imágenes generalizan eficientemente hacia

dominios específicos como la clasificación botánica, incluso cuando el volumen de datos del dominio objetivo es reducido (3,670 imágenes).

6.3 Modelo 3: MobileViT XS — Fine-Tuning con Preprocesamiento Avanzado (96%)

El salto de 85% a **96% de exactitud** —una mejora de 11 puntos porcentuales sobre el modelo anterior y de 17 sobre la línea base—no se explica por cambios en la arquitectura ni en los hiperparámetros, que son idénticos en ambos casos, sino por la estrategia de partición del dataset. En el modelo 2 se descarga el archivo comprimido directamente, se ordenan las imágenes alfabéticamente por nombre de archivo y se aplica un corte secuencial 90/10. Dado que las imágenes están agrupadas por carpetas de clase dentro del archivo, este ordenamiento introduce un sesgo de distribución entre los conjuntos de entrenamiento y validación, exponiendo al modelo a una distribución de clases desequilibrada durante la evaluación. En el modelo 3 se usó la función de carga tfds.load de TensorFlow, que aplica una partición más equilibrada de clases, resultando en una estimación fiel del rendimiento de generalización del modelo, explicando las diferencias de exactitud.

7. Conclusiones

A partir de los resultados obtenidos, se extraen las siguientes conclusiones:

- MobileViT constituye una solución altamente eficiente para tareas de visión por computadora en dispositivos con recursos computacionales y de memoria limitados, combinando la eficiencia de las CNN con la capacidad expresiva de los Transformers.
- El fine-tuning sobre pesos preentrenados en ImageNet-1k supera sistemáticamente al entrenamiento desde cero en datasets de tamaño reducido, ratificando el valor del aprendizaje por transferencia como estrategia prioritaria.
- La combinación de convoluciones y Transformers permite alcanzar precisiones de estado del arte (96%) con una fracción de los parámetros de modelos tradicionales como ResNet o EfficientNet.
- La estrategia de carga y partición del dataset tiene un impacto determinante sobre la validez de las métricas de evaluación.

8. Trabajo Futuro

Con el objetivo de continuar mejorando el rendimiento y viabilidad de despliegue de los modelos, se proponen las siguientes líneas de trabajo:

8.1 Optimización para Despliegue

- Cuantización post-entrenamiento: conversión del modelo al formato TFLite con precisión entera de 8 bits (INT8) para reducir la huella de memoria y acelerar la inferencia en dispositivos móviles Android/iOS.
- Poda de pesos (Pruning): eliminación iterativa de conexiones de baja magnitud para reducir el tamaño del modelo sin pérdida crítica de precisión.

8.2 Mejoras de Entrenamiento

- Ajuste sistemático de hiperparámetros (tasa de aprendizaje, batch size, scheduler) mediante búsqueda en cuadrícula o algoritmos Bayesianos para estabilizar la convergencia.
- Exploración de estrategias de descongelado progresivo de capas (gradual unfreezing) para aprovechar al máximo los pesos preentrenados.
- Evaluación sobre datasets de mayor escala o en dominios de aplicación real (e.g., clasificación de plantas medicinales, control de calidad agroindustrial).

8.3 Extensiones Arquitectónicas

- Evaluación de MobileViTv2 y MobileViTv3, que incorporan mejoras en el mecanismo de atención para mayor eficiencia.
- Integración de MobileViT como backbone en tareas de detección de objetos y segmentación semántica.

9. Referencias

[1] Mehta, S. & Rastegari, M. (2021). MobileViT: Light-weight, General-purpose, and Mobile-friendly Vision Transformer. Apple Inc. arXiv:2110.02178.

[2] Hugging Face Hub — Modelo base: apple/mobilevit-small. Disponible en: https://huggingface.co/apple/mobilevit-small

[3] TensorFlow Datasets — tf_flowers. Disponible en: https://www.tensorflow.org/datasets/catalog/tf_flowers

[4] Wolf, T. et al. (2020). Transformers: State-of-the-Art Natural Language Processing. Hugging Face. Proceedings of EMNLP 2020 (System Demonstrations).

[5] Howard, A. et al. (2017). MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications. arXiv:1704.04861.